



EXTENSÃO DO SPECMINE E WEBSPECMINE PARA ANÁLISE NÃO SUPERVISIONADA

Projeto Bioinformática

Proposto pelos docentes:
Miguel Rocha, Diogo Cachetas e
Marcelo Maraschin





CONTEXTO

O Problema:

- **Dados de metabolómica** (NMR, GC-MS, LC-MS) têm centenas a milhares de variáveis por amostra.
 - **Análise manual é inviável** — é necessário software especializado.
 - Métodos não supervisionados são fundamentais para descobrir padrões, controlar qualidade e preparar análises supervisionadas.
- 



OBJETIVOS

O projeto propõe integrar métodos modernos de redução de dimensionalidade (UMAP, t-SNE, ICA) e novos algoritmos de clustering (DBSCAN, HDBSCAN, GMM) no package R specmine, e depois expô-los numa interface acessível em WebSpecmine.





CONTRIBUIÇÕES AO SPECMINE

01

Função de redução de dimensionalidade: UMAP, t-SNE, ICA

02

Novos algoritmos de clustering: DBSCAN, HDBSCAN, GMM

03

Interface uniforme para todos os métodos, compatível com objetos specmine

04

Parâmetros configuráveis por argumento



UMAP VS T-SNE VS ICA PORQUÊ CADA UM?

Tabela 1-Critérios de seleção e comparação entre os métodos PCA, ICA, t-SNE e UMAP para análise e visualização de dados estruturados.

Método	Tipo	Estrutura global	Escalabilidade	Interpretabilidade	Uso recomendado
PCA já existia	Linear	Sim	Alta	Alta	Exploração inicial, componentes explicadas
ICA novo	Linear	Parcial	Alta	Média	Separar fontes independentes de variação
t-SNE novo	Não-linear	Não	Baixa $O(n^2)$	Média	Visualizar subestruturas locais finas
UMAP novo	Não-linear	Sim	Alta (~linear)	Média	Visualização rápida e consistente, dados ômicos

DBSCAN VS HDBSCAN VS GMM

PORQUÊ CADA UM?

GMM

- **Modelo probabilístico** — assume mistura de **Gaussianas**.
- Atribui a cada amostra uma **probabilidade de pertença a cada cluster**.
- Útil quando os grupos se **sobrepõem ou têm diferentes variâncias**.
- **Parâmetro**: número de clusters k .
- **Vantagem**: saída probabilística interpretável

HDBSCAN

- **Extensão hierárquica do DBSCAN** — adapta-se a densidades variáveis.
- **Não exige eps fixo**; mais robusto e automático.
- Ideal para dados metabolômicos onde clusters têm densidades diferentes.
- **Parâmetro**: apenas minPts.
- **Vantagem**: menos sensível à parametrização.

DBSCAN

- **Baseia-se em densidade** — agrupa pontos em regiões densas.
- **Detecta automaticamente** outliers (ruído).
- Não assume forma esférica dos clusters.
- Parâmetros: eps(raio) e minPts.
- **Limitação**: sensível ao eps — difícil de ajustar.

WEBSPECMINE

O que é o WebSpecmine

App web construída em R Shiny sobre o specmine. Permite que investigadores sem experiência em programação acessem a análises sofisticadas através de menus e botões.

O que já existia

- **WebSpecmine:** app construída, acessível a utilizadores sem programação.
- Já apresentava PCA e clustering básico, mas sem UMAP, t-SNE, ICA, DBSCAN, HDBSCAN nem GMM.




Fig. 1: Interface gráfica da página inicial (Overview) da aplicação web WebSpecmine e contextualização das suas funcionalidades base.

RESULTADOS




Fig. 2: Projeção bidimensional das amostras através da Análise de Componentes Principais (PCA).




Fig. 3: Projeção tridimensional das amostras nos três primeiros componentes principais obtidos por PCA.




Fig. 4: Projeção bidimensional das amostras utilizando o algoritmo Uniform Manifold Approximation and Projection (UMAP).




Fig. 5: Representação tridimensional das amostras obtida através do algoritmo UMAP.

RESULTADOS




Fig. 6: Gráfico de dispersão bidimensional das amostras utilizando o algoritmo t-Distributed Stochastic Neighbor Embedding (t-SNE).




Fig. 7: Representação tridimensional das amostras obtida através do algoritmo t-SNE (t-SNE 3D Scores Plot).




Fig. 8: Projeção bidimensional das amostras através da Análise de Componentes Independentes (ICA).




Fig. 9: Projeção tridimensional das amostras nos três primeiros componentes independentes obtidos por ICA (ICA 3D Scores Plot).

RESULTADOS




Fig. 10: Projeção bidimensional das amostras através da Análise de Componentes Principais (PCA).




Fig.11: Gráfico de dispersão bidimensional das amostras agrupadas através do algoritmo HDBSCAN (Hierarchical Density-Based Spatial Clustering of Applications with Noise).




Fig. 12: Gráfico de dispersão bidimensional das amostras agrupadas através do método de Agrupamento Hierárquico (Hierarchical Clustering - hc).

RESULTADOS




Fig. 12: Mapa de calor (HCA Heatmap) dos perfis espectrais e tabela correspondente com os valores de peso (loadings) das principais características (features) selecionadas por componente principal.




Fig. 13: Mapa de calor de cargas (Loading Heatmap) para as três primeiras componentes principais (PC1, PC2 e PC3) acompanhado pelo respectivo dendrograma da análise de agrupamento hierárquico (HCA Dendrogram).





Fig. 14: Gráfico de barras com os valores de peso (PCA Loadings) das características mais relevantes que contribuem para a variabilidade da primeira componente principal (PC1).



OBJETIVOS A MELHORAR

- Métricas de qualidade de clustering ainda a afinar.
 - Análise de sensibilidade a parâmetros não concluída.
 - Comparar métodos quantitativamente e documentar quando cada um é mais adequado.
 - Validação em mais datasets
 - Afinar visualizações e melhorar feedback ao utilizador na app.
- 

CONCLUSÃO

01

- O projeto colmata uma lacuna real: não existia uma ferramenta que combinasse UMAP, t-SNE, ICA e clustering avançado numa interface acessível a utilizadores sem programação

02

- A integração de interpretabilidade no specmine permite ao investigador não só visualizar os dados projetados, mas também compreender quais as variáveis que mais contribuem para cada dimensão.

03

- A extensão foi feita em dois níveis: backend analítico (specmine) e interface acessível (WebSpecmine).

INTELIGÊNCIA ARTIFICIAL

Não foi utilizado qualquer tipo de inteligência artificial na realização desta apresentação